

目录

1. 概率基础与变分推断
2. DDPM
3. Score matching、SDE 与概率流 ODE
4. Flow matching 与 rectified flow
5. 自编码器、VAE 与潜空间生成
6. 条件生成、DiT 与 MM-DiT

符号与时间约定

全文中，随机向量均用小写字母表示， I 为单位矩阵， $\mathcal{N}(\mu, \Sigma)$ 为高斯分布。 $\mathbb{E}$ 表示期望， ∇_x 表示对 x 求梯度。

DDPM 与正向 SDE： x_0 是数据，时间增大意味着加噪；生成时从大时间向小时间走。

Flow matching： x_0 是噪声， x_1 是数据；生成时从 $t=0$ 积分到 $t=1$ 。

1. 概率基础与变分推断

1.1 联合分布、条件分布与边缘分布

概率的乘法公式为

$$p(x, z) = p(x \mid z) p(z) = p(z \mid x) p(x).$$

其中 $p(x, z)$ 描述两个变量同时取值的规律， $p(x \mid z)$ 描述固定 z 后 x 的分布。对不关心的变量积分，就得到边缘分布：

$$p(x) = \int p(x, z) \mathrm{d}z.$$

将乘法公式重复展开，可以得到链式分解：

$$p(x_0, \dots, x_T) = p(x_0) \prod_{t=1}^T p(x_t \mid x_0, \dots, x_{t-1}).$$

若过程满足马尔可夫性，即下一步只依赖当前状态，则条件可以简化成 $p(x_t \mid x_{t-1})$ 。DDPM 的正向加噪过程正是这样构造的。

1.2 各向同性高斯与重参数化

对 $x \in \mathbb{R}^d$ ，各向同性高斯的密度为

$$p(x) = \frac{1}{(2\pi\sigma^2)^{d/2}} \exp\left(-\frac{\|x - \mu\|^2}{2\sigma^2}\right).$$

\$\$

各向同性表示协方差为 $\sigma^2 I$ ：不同坐标不相关，且每个方向的方差相同。采样可以写成

\$\$

$\epsilon \sim \mathcal{N}(0, I), \text{qqquad } x = \mu + \sigma \epsilon.$

\$\$

重参数化将随机性集中于 ϵ ，使分布参数通过确定性变换参与计算，便于推导扩散过程及对 VAE 进行反向传播。

1.3 KL 散度与 ELBO

设 z 是潜变量，模型的联合分布为 $p_{\theta}(x, z) = p_{\theta}(x | z)p(z)$ 。我们希望最大化 $\log p_{\theta}(x)$ ，但对 z 的积分往往难以直接计算。

引入近似后验 $q_{\phi}(z | x)$ ，在相应密度和积分存在、支持集兼容的条件下，有

\$\$

$\log p_{\theta}(x) = \log \mathbb{E}_{q_{\phi}(z | x)} \left[\frac{p_{\theta}(x, z)}{q_{\phi}(z | x)} \right].$

\$\$

由于 $\log$ 是凹函数，Jensen 不等式给出

\$\$

$\log p_{\theta}(x) \geq \mathbb{E}_{q_{\phi}(z | x)} [\log p_{\theta}(x, z) - \log q_{\phi}(z | x)] = \mathcal{L}_{\text{ELBO}}.$

\$\$

证据下界（evidence lower bound，ELBO）是对数边缘似然的下界。展开联合分布，得到

\$\$

$\mathcal{L}_{\text{ELBO}} = \mathbb{E}_{q_{\phi}(z | x)} [\log p_{\theta}(x | z)] - D_{\text{KL}}(q_{\phi}(z | x) \parallel p(z)).$

\$\$

第一项衡量重建似然，第二项约束近似后验与先验的差异。

下界差距的推导。 由贝叶斯公式 $p_{\theta}(x, z) = p_{\theta}(z | x)p_{\theta}(x)$,

\$\$

$$\begin{aligned}$$

$$D_{\text{KL}}(q_{\phi}(z | x) \parallel p_{\theta}(z | x)) = \mathbb{E}_{q_{\phi}} [\log q_{\phi}(z | x) - \log p_{\theta}(z | x)]$$

$$= \mathbb{E}_{q_{\phi}} [\log q_{\phi}(z | x) - \log p_{\theta}(z | x) + \log p_{\theta}(x, z) - \log p_{\theta}(x)]$$

$$= \mathbb{E}_{q_{\phi}} [\log q_{\phi}(z | x) - \log p_{\theta}(x, z) + \log p_{\theta}(x)]$$

$$= \log p_{\theta}(x) - \mathcal{L}_{\text{ELBO}}.$$

$$\end{aligned}$$

\$\$

因此

\$\$

$$\log p_{\theta}(x) - \mathcal{L}_{\mathrm{ELBO}} = D_{\mathrm{KL}}(q_{\phi}(z|x) \parallel p_{\theta}(z|x)) \geq 0.$$

\$\$

近似后验与真实后验几乎处处相等时取等号。DDPM 与 VAE 使用同一变分框架，但潜变量的定义不同。

2. DDPM

 DDPM 正向加噪与反向去噪示意图，右侧突出显示从噪声逐步恢复图像的过程

图 1 正向过程按预设分布逐步加噪，反向过程学习各步的条件分布。右侧突出显示反向去噪链。来源：CME 296 Lecture 1，第 37 页（PDF 页码）。点击图片可查看原尺寸。

2.1 正向加噪

设 $x_0 \sim p_{\mathrm{data}}$ ，噪声日程满足 $0 < \beta_t < 1$ ，记

\$\$

$$\alpha_t = 1 - \beta_t, \quad \bar{\alpha}_t = \prod_{s=1}^t \alpha_s, \quad \bar{\alpha}_0 = 1.$$

\$\$

正向转移定义为

\$\$

$$q(x_t | x_{t-1}) = \mathcal{N}(\sqrt{\alpha_t} x_{t-1}, \beta_t).$$

\$\$

等价地， $x_t = \sqrt{\alpha_t} x_{t-1} + \sqrt{\beta_t} \epsilon_t$ ，其中各步的 ϵ_t 独立且服从标准高斯。

递推展开后，数据项的系数为 $\sqrt{\bar{\alpha}_t}$ ，其余项是独立高斯的线性组合，仍为高斯。若累计噪声方差为 v_t ，则

\$\$

$$v_t = \alpha_t v_{t-1} + \beta_t = \alpha_t (1 - \bar{\alpha}_{t-1}) + 1 - \alpha_t = 1 - \bar{\alpha}_t.$$

\$\$

所以

\$\$

$$q(x_t | x_0) = \mathcal{N}(\sqrt{\bar{\alpha}_t} x_0, (1 - \bar{\alpha}_t) I),$$

\$\$

\$\$

$$x_t = \sqrt{\bar{\alpha}_t} x_0 + \sqrt{1 - \bar{\alpha}_t} \epsilon, \quad \epsilon \sim \mathcal{N}(0, I).$$

\$\$

因此，训练时可直接采样任意时刻的 x_t ，无需逐步加噪。当 $\bar{\alpha}_T$ 接近零时，终点分布近似标准高斯。

2.2 反向去噪

生成模型从 $p(x_T) = \mathcal{N}(0, I)$ 出发，学习

$$p_{\theta}(x_{0:T}) = p(x_T) \prod_{t=1}^T p_{\theta}(x_{t-1} | x_t).$$

真实反向分布 $q(x_{t-1} | x_t)$ 一般难以直接求出，但训练时知道干净样本 x_0 ，因此可以使用解析可得的 $q(x_{t-1} | x_t, x_0)$ 。

对 $t \geq 2$ ，贝叶斯公式给出

$$q(x_{t-1} | x_t, x_0) \propto q(x_t | x_{t-1}) q(x_{t-1} | x_0).$$

令 $y = x_{t-1}$ ，忽略与 y 无关的常数，其对数为

$$-\frac{1}{2} \frac{\|x_t - \sqrt{\alpha_t} y\|^2}{\beta_t} - \frac{1}{2} \frac{\|y - \sqrt{\bar{\alpha}_{t-1}} x_0\|^2}{1 - \bar{\alpha}_{t-1}}.$$

展开平方项，将其写成 $-\frac{1}{2} A y^2 + b y + C$ ，其中 C 与 y 无关，且

$$A = \frac{\alpha_t}{\beta_t} + \frac{1}{1 - \bar{\alpha}_{t-1}}, \quad b = \frac{\sqrt{\alpha_t}}{\beta_t} x_t + \frac{\sqrt{\bar{\alpha}_{t-1}}}{1 - \bar{\alpha}_{t-1}} x_0.$$

由于 $A > 0$ ，配方可得

$$-\frac{1}{2} A y^2 + b y = -\frac{1}{2} A \left(y - A^{-1} b \right)^2 + \frac{1}{2} A^{-1} b^2.$$

所以后验是均值为 $A^{-1} b$ 、协方差为 A^{-1} 的高斯分布，即

$$q(x_{t-1} | x_t, x_0) = \mathcal{N}(\tilde{\mu}_t, \tilde{\beta}_t),$$

其中

$$\tilde{\beta}_t^{-1} = \frac{\alpha_t}{\beta_t} + \frac{1}{1 - \bar{\alpha}_{t-1}},$$

$$\tilde{\beta}_t^{-1} \tilde{\mu}_t = \frac{\sqrt{\alpha_t}}{\beta_t} x_t + \frac{\sqrt{\bar{\alpha}_{t-1}}}{1 - \bar{\alpha}_{t-1}} x_0.$$

$\bar{\alpha}_{t-1}x_0$.

\$\$

于是

\$\$

$\tilde{\beta}_t = \frac{1 - \bar{\alpha}_{t-1}}{1 - \bar{\alpha}_t} \beta_t$,

\$\$

\$\$

$\tilde{\mu}_t = \frac{\sqrt{\bar{\alpha}_{t-1}} \beta_t}{1 - \bar{\alpha}_t} x_0 + \frac{\sqrt{\alpha_t} (1 - \bar{\alpha}_{t-1})}{1 - \bar{\alpha}_t} x_t$.

\$\$

把 $x_0 = (x_t - \sqrt{1 - \bar{\alpha}_t} \epsilon) / \sqrt{\bar{\alpha}_t}$ 代入，又得到

\$\$

$\tilde{\mu}_t = \frac{1}{\sqrt{\alpha_t}} \left(x_t - \frac{\beta_t}{\sqrt{1 - \bar{\alpha}_t}} \epsilon \right)$.

\$\$

这就是学习预测噪声能够确定去噪均值的原因。

2.3 从 ELBO 到噪声预测损失

把整条轨迹 $x_{1:T}$ 视为潜变量。对固定的 x_0 ，负 ELBO 为

\$\$

$\mathcal{J}_{\text{VLB}}(x_0)$

$= -\mathbb{E}_{q(x_{1:T} \mid x_0)} \left[\log \frac{q(x_{1:T} \mid x_0)}{p_{\theta}(x_{0:T})} \right]$.

\$\$

利用正向链的马尔可夫性，按相反次序分解条件联合分布：

\$\$

$q(x_{1:T} \mid x_0) = q(x_T \mid x_0) \prod_{t=2}^T q(x_{t-1} \mid x_t, x_0)$.

\$\$

再代入生成模型的分解式，得到

\$\$

$\begin{aligned}$

$\log \frac{q(x_{1:T} \mid x_0)}{p_{\theta}(x_{0:T})}$

$\&= \log \frac{q(x_T \mid x_0)}{p(x_T)}$

$\&\quad + \sum_{t=2}^T \log \frac{q(x_{t-1} \mid x_t, x_0)}{p_{\theta}(x_{t-1} \mid x_t)}$

$\quad - \log p_{\theta}(x_0 \mid x_1)$.

$\end{aligned}$

\$\$

先对各条件变量取期望，再对数据分布取平均，可得

\$\$

$$\mathcal{J}_{\mathrm{VLB}} = \mathbb{E}_q[\left[L_T + \sum_{t=2}^T L_{t-1} + L_0\right],$$

\$\$

其中三类项分别是

\$\$

$$L_T = D_{\mathrm{KL}}[q(x_T \mid x_0) \mid p(x_T)]$$

\$\$

\$\$

$$L_{t-1} = D_{\mathrm{KL}}[q(x_{t-1} \mid x_t, x_0) \mid p_{\theta}(x_{t-1} \mid x_t)]$$

\$\$

\$\$

$$L_0 = -\log p_{\theta}(x_0 \mid x_1)$$

\$\$

L_T 匹配终点先验, L_{t-1} 匹配反向转移, L_0 是最后一步的重建项。

设反向模型的方差固定为 σ_t^2 , 并用 $\epsilon_{\theta}(x_t, t)$ 替代后验均值中的噪声。两个高斯分布的 KL 散度可写为

\$\$

$$L_{t-1} = \frac{1}{2\sigma_t^2} \|\tilde{\mu}_t - \mu_{\theta}(x_t, t)\|^2 + C_t$$

\$\$

由均值参数化,

\$\$

$$\begin{aligned} & \tilde{\mu}_t - \mu_{\theta}(x_t, t) \\ &= \frac{\beta_t}{\sqrt{\alpha_t(1 - \bar{\alpha}_t)}} \left(\epsilon_{\theta}(x_t, t) - \epsilon \right) \end{aligned}$$

\$\$

代入得到

\$\$

$$L_{t-1} = \frac{\beta_t^2}{2\sigma_t^2 \alpha_t(1 - \bar{\alpha}_t)} \|\epsilon_{\theta}(x_t, t) - \epsilon\|^2 + C_t$$

\$\$

固定方差时, C_t 与网络参数无关; 若方差也参与学习, 则须保留相应项。

实际常用的简化目标去掉了上述时间权重:

\$\$

$$\mathcal{L}_{\mathrm{simple}} = \mathbb{E}_{t, x_0, \epsilon}[\|\epsilon_{\theta}(\sqrt{\bar{\alpha}_t}x_0 + \sqrt{1 - \bar{\alpha}_t}\epsilon, t)\|^2]$$

\$\$

简化噪声 MSE 与原始负 ELBO 的区别在于各时间步的权重。

2.4 训练与采样

训练时抽取数据、时间和噪声，直接构造 x_t ，再做一次噪声预测回归。虽然单个 x_t 不能唯一确定当初加入的噪声，但平方损失的最优解是条件均值 $\mathbb{E}[\epsilon \mid x_t, t]$ 。

采样时从 $x_T \sim \mathcal{N}(0, I)$ 开始，按 $t=T, \dots, 1$ 更新：

$$x_{t-1} = \frac{1}{\sqrt{\alpha_t}} \left(x_t - \frac{\beta_t}{\sqrt{1 - \bar{\alpha}_t}} \epsilon_{\theta}(x_t, t) \right) + \sigma_t \xi.$$

其中 $\xi_i \sim \mathcal{N}(0, I)$ ，常见实现最后一步不再额外加噪。 σ_t 的选择应与模型、训练和采样器的设定一致。

2.5 DDIM

DDIM 不要求采样时严格遵循原来的马尔可夫反向链。先估计干净样本：

$$\hat{x}_0 = \frac{x_t - \sqrt{1 - \bar{\alpha}_t} \epsilon_{\theta}(x_t, t)}{\sqrt{\bar{\alpha}_t}}.$$

对于较早时刻 $s < t$ ，确定性的 DDIM 更新写为

$$x_s = \sqrt{\bar{\alpha}_s} \hat{x}_0 + \sqrt{1 - \bar{\alpha}_s} \epsilon_{\theta}(x_t, t).$$

该更新允许使用较稀疏的时间网格。“确定性”指给定初始噪声后轨迹确定；网络误差与离散化误差仍然存在。

3. Score matching、SDE 与概率流 ODE

3.1 得分函数

概率密度 $p_t(x)$ 的 score 定义为

$$s_t(x) = -\nabla_x \log p_t(x).$$

它是一个与 x 同维的向量，指向局部对数密度上升最快的方向。若密度只差一个与 x 无关的归一化常数，取梯度后该常数消失。

仅沿得分方向做梯度上升不能实现分布采样。朗之万（Langevin）动力学还需加入噪声：

$$x_{k+1} = x_k + \eta s(x_k) + \sqrt{2\eta} \xi_k.$$

在合适的正则性与遍历条件下，对应的连续过程以 p 为平稳分布；有限步长的离散算法通常仍有偏差。

3.2 去噪得分匹配

设扰动核为

$$q_t(x_t \mid x_0) = \mathcal{N}(m_{t|x_0}, \nu_t^2).$$

它的条件 score 可以直接计算：

$$\nabla_{x_t} \log q_t(x_t \mid x_0) = -\frac{x_t - m_{t|x_0}}{\nu_t^2} = -\frac{\epsilon_t}{\nu_t}.$$

然而采样需要的是边缘分布 $p_t(x_t) = \int q_t(x_t \mid x_0) p_{\{\text{data}\}}(x_0) dx_0$ 的 score。

在可以交换微分与积分的条件下，

$$\nabla_x \log p_t(x) = \frac{\int \nabla_x q_t(x \mid x_0) p_{\{\text{data}\}}(x_0) dx_0}{p_t(x)}.$$

利用 $\nabla q = q \nabla \log q$ 和贝叶斯公式，得到

$$\nabla_x \log p_t(x) = \mathbb{E}[\nabla_x \log q_t(x \mid x_0) \mid x_t = x].$$

记条件 score 为随机向量 Y ，其条件均值为 $\bar{Y} = \mathbb{E}[Y \mid x_t, t]$ 。平方误差分解为

$$\mathbb{E}[\|s_{\theta} - Y\|^2] = \mathbb{E}[\|s_{\theta} - \bar{Y}\|^2] + \mathbb{E}[\|Y - \bar{Y}\|^2].$$

其中交叉项为零：

$$\begin{aligned} \mathbb{E}[\|s_{\theta} - \bar{Y}\| \cdot \|Y - \bar{Y}\|] &= \mathbb{E}[\|s_{\theta} - \bar{Y}\| \cdot \mathbb{E}[Y - \bar{Y} \mid x_t, t]] \\ &= 0. \end{aligned}$$

第二项与网络参数无关。因此，对条件得分进行回归与学习边缘得分具有相同的最优解。

对于 DDPM, 有 $m_t = \sqrt{\bar{\alpha}_t}$ 、 $\nu_t = \sqrt{1 - \bar{\alpha}_t}$, 于是噪声预测与 score 预测的关系为

$$s_\theta(x_t, t) = -\frac{\epsilon_\theta(x_t, t)}{\sqrt{1 - \bar{\alpha}_t}}.$$

3.3 从 DDPM 到连续时间 SDE

一般正向随机微分方程写作

$$\mathrm{d}x = f(x, t) \mathrm{d}t + g(t) \mathrm{d}W_t.$$

f 是漂移项, 描述确定性变化; W_t 是标准 Wiener 过程, 其增量协方差为 $\mathrm{d}t$; g 控制随机扰动强度。这里假设扩散系数只依赖时间, 若依赖空间, 后面的公式需要相应修正。

将 DDPM 一步的噪声方差设为 $\beta(t) \Delta t$ 。用 $\sqrt{1-a} = 1 - a/2 + O(a^2)$ 展开, 有

$$x_{t+\Delta t} - x_t \approx -\frac{1}{2} \beta(t) x_t \Delta t + \sqrt{\beta(t)} \sqrt{\Delta t} \epsilon.$$

连续极限即 variance-preserving SDE:

$$\mathrm{d}x = -\frac{1}{2} \beta(t) x \mathrm{d}t + \sqrt{\beta(t)} \mathrm{d}W_t.$$

“方差保持”并不要求每个给定数据点的条件方差恒定; 它指在输入具有单位协方差的条件下, 该过程保持单位协方差。另一个常见选择是 VE-SDE, 通过不断增大的噪声方差扩散数据。

3.4 反向 SDE

在相应光滑性和时间反演条件下, 反向过程为

$$\mathrm{d}x = \left[f(x, t) - g(t)^2 \nabla_x \log p_t(x) \right] \mathrm{d}t + g(t) \mathrm{d}\bar{W}_t.$$

此式按 $t = T$ 到 0 使用, $\mathrm{d}t$ 是负的时间增量, $\bar{W}_t$ 是反向时间中的 Wiener 过程。若使用正步长 $h > 0$ 向前编写“反向采样”代码, 则 Euler 更新是

$$x_{t-h} \approx x_t - \left[f(x_t, t) - g(t)^2 s_\theta(x_t, t) \right] h + g(t) \sqrt{h} \xi.$$

3.5 概率流 ODE

与上述 SDE 对应的 probability flow ODE 为

$$\frac{dx}{dt} = f(x, t) - \frac{1}{2}g(t)^2 \nabla_x \log p_t(x).$$

推导。 SDE 的密度满足 Fokker–Planck 方程：

$$\frac{\partial p_t}{\partial t} = -\nabla \cdot (f p_t) + \frac{1}{2}g(t)^2 \Delta p_t.$$

由 $\nabla p_t = p_t \nabla \log p_t$ ，可以改写为

$$\frac{\partial p_t}{\partial t} = -\nabla \cdot \left[p_t \left(f - \frac{1}{2}g(t)^2 \nabla \log p_t \right) \right].$$

这恰好是速度场 $f - \frac{1}{2}g^2 \nabla \log p_t$ 的连续性方程。因此，在使用精确 score、相同初始密度并满足解的条件时，ODE 与 SDE 具有相同的单时刻边缘分布。

相同的边缘分布不意味着相同的路径分布：ODE 给定起点后轨迹确定，SDE 则沿途持续注入随机性。

4. Flow matching 与 rectified flow

x_0 为简单先验噪声， x_1 为数据。

4.1 轨迹、速度场与概率路径

三种对象需要区分：

轨迹 $x_t = \psi_t(x_0)$ ：一个粒子随时间如何运动。

速度场 $u_t(x)$ ：时间 t 、位置 x 处应当具有的速度。

概率路径 p_t ：所有粒子共同形成的分布如何变化。

它们通过 ODE 连接：

$$\frac{d}{dt} \psi_t(x_0) = u_t(\psi_t(x_0)), \quad \psi_0(x_0) = x_0.$$

给定初始分布 p_0 ， p_t 是随机变量 $\psi_t(x_0)$ 的分布，称为 p_0 在流映射下的推前分布。

4.2 解的存在性与唯一性

若速度场在初值附近对时间连续、对空间变量满足局部一致 Lipschitz 条件，则 ODE 初值问题存在唯一的局部解。

例如 $\dot{x} = \sqrt{x}$ 、 $x(0) = 0$ 在非负半轴上不满足原点附近的 Lipschitz 条件。除了恒等于零的解，对于任意 $c \geq 0$ ，还有

\$\$

$$x(t) = \begin{cases} 0, & 0 \leq t \leq c, \\ (t-c)^2/4, & t > c. \end{cases}$$

\$\$

上述解在 $t=c$ 处的左右导数均为零，且在两段上都满足微分方程，因此同一初值对应多个解。Lipschitz 条件是局部唯一性的充分条件，而非必要条件。

4.3 连续性方程的推导

粒子流既不创造也不消灭概率质量，所以密度满足

\$\$

$$\partial_t p_t(x) + \nabla \cdot (p_t(x) u_t(x)) = 0.$$

\$\$

证明： 取光滑且紧支撑的函数 φ 。由链式法则，

\$\$

$$\frac{d}{dt} \int \varphi(x) p_t(x) dx = \int \nabla \varphi(x) \cdot u_t(x) p_t(x) dx.$$

\$\$

由于 φ 具有紧支撑，分部积分的边界项为零。另一方面， $\frac{d}{dt} \int \varphi(x) p_t(x) dx = \int \nabla \varphi(x) \cdot u_t(x) p_t(x) dx$ ，因此

\$\$

$$\int \nabla \varphi(x) \cdot u_t(x) p_t(x) dx = - \int \varphi(x) \nabla \cdot (p_t(x) u_t(x)) dx.$$

\$\$

移项可得

\$\$

$$\int \varphi(x) \left[\partial_t p_t(x) + \nabla \cdot (p_t(x) u_t(x)) \right] dx = 0.$$

\$\$

该式对任意光滑紧支撑测试函数成立，即为连续性方程的弱形式；密度与速度场足够光滑时，也得到点态形式。

4.4 从条件路径构造可训练的速度

最简单的插值为

\$\$

$$x_t = (1-t)x_0 + tx_1, \quad \dot{x}_t = x_1 - x_0.$$

\$\$

固定一个数据点 x_1 ，若 $x_0 \sim \mathcal{N}(0, I)$ 且与它独立，则

\$\$

$$p_t(x | x_1) = \mathcal{N}(tx_1, (1-t)^2 I), \quad 0 \leq t < 1.$$

\$\$

由 $x_0 = (x - tx_1)/(1-t)$ 得到条件速度场

\$\$

$$u_t(x \mid x_1) = \frac{x_1 - x}{1-t}.$$

\$\$

沿采样得到的插值点代入，这个表达式就等于 $x_1 - x_0$ 。后者是训练时更直接、也无需除以 $1-t$ 的目标。

当 $t \rightarrow 1$ 时，上述条件高斯收缩成点质量，因此带分母的公式不能直接在 $t=1$ 代入。训练通常从连续区间采样时间，实际求解也需要妥善处理端点。

4.5 边缘速度与条件速度

边缘概率路径为

\$\$

$$p_t(x) = \int p_t(x \mid x_1) p_{\{\mathrm{data}\}}(x_1) \mathrm{d}x_1.$$

\$\$

每个条件路径都满足连续性方程。将这些方程对 x_1 积分，就有

\$\$

$$\partial_t p_t(x) = -\nabla \cdot \int p_t(x \mid x_1) u_t(x \mid x_1) p_{\{\mathrm{data}\}}(x_1) \mathrm{d}x_1.$$

\$\$

因此一个能够生成该边缘路径的速度场是

\$\$

$$u_t(x) = \frac{\int p_t(x \mid x_1) u_t(x \mid x_1) p_{\{\mathrm{data}\}}(x_1) \mathrm{d}x_1}{p_t(x)} = \mathbb{E}[u_t(x \mid x_1) \mid x_t = x].$$

\$\$

注意平均的权重是后验 $p(x_1 \mid x_t = x)$ ，不是对所有数据点做等权平均。给定一条密度路径，能够实现它的速度场也不必唯一；这里构造的是其中一个。

4.6 FM 与 CFM 的等价性

理想的 flow matching 目标是

\$\$

$$\mathcal{L}_{\{\mathrm{FM}\}} = \mathbb{E}_{t, x_t} \|\nabla_{\theta} (x_t, t) - u_t(x_t)\|^2,$$

\$\$

但边缘速度难以计算。实际训练采用 conditional flow matching:

\$\$

$$\mathcal{L}_{\{\mathrm{CFM}\}} = \mathbb{E}_{t, x_0, x_1} \|\nabla_{\theta} ((1-t)x_0 + tx_1, t) - (x_1 - x_0)\|^2.$$

\$\$

证明。

令 $U = x_1 - x_0$, $\bar{U} = \mathbb{E}[U \mid x_t, t] = u_t(x_t)$, 简记 $v = v_\theta(x_t, t)$ 。由 $v - U = (v - \bar{U}) - (U - \bar{U})$,

$$\begin{aligned} & \|v - U\|^2 \\ &= \|v - \bar{U}\|^2 + \|U - \bar{U}\|^2 \\ &\quad - 2(v - \bar{U})^\top (U - \bar{U}). \end{aligned}$$

给定 (x_t, t) 后, $v - \bar{U}$ 是确定量, 而 $\mathbb{E}[U - \bar{U} \mid x_t, t] = 0$, 故

$$\begin{aligned} & \mathbb{E}[(v - \bar{U})^\top (U - \bar{U})] \\ &= \mathbb{E}[(v - \bar{U})^\top] \mathbb{E}[U - \bar{U} \mid x_t, t] = 0. \end{aligned}$$

两边取期望, 得到

$$\mathcal{L}_{\text{CFM}} = \mathcal{L}_{\text{FM}} + \mathbb{E} \|U - \bar{U}\|^2.$$

第二项不依赖 θ , 所以两个目标具有相同的最优解; 允许交换微分与期望时, 其参数梯度也相同。

训练时不必求解 ODE; 只需采样 (x_0, x_1, t) 并做速度回归。采样时才从 $x_0 \sim p_0$ 出发, 解 $\dot{x}_t = v_\theta(x_t, t)$ 。

 [从高斯分布到数据分布的两条弯曲 ODE 采样轨迹](#)

图 2 流匹配的 ODE 采样轨迹。条件插值虽为直线, 边缘速度是条件速度的平均, 积分轨迹仍可能弯曲。图中的 z_1 表示模型生成的终点, 不是预先配对的数据点。来源: CME 296 Lecture 3, 第 76 页。

4.7 Rectified flow 与 reflow

在这里讨论的线性插值、速度回归设定下, rectified flow 与前面的训练形式一致。Reflow 则使用已学到的 ODE 建立新的端点对: 采样 Z_0 , 积分得到 Z_1 , 再基于这对端点的直线插值重新训练。

新的端点对由旧模型的传输映射确定, 不再独立采样。其作用可用以下能量不等式说明。

能量不等式。

对旧端点对 (Z_0, Z_1) , 记 $D = Z_1 - Z_0$ 、 $X_t = (1-t)Z_0 + tZ_1$ 。设新的精确回归场为 $v_t(x) = \mathbb{E}[D \mid X_t = x]$, 由该场产生的新轨迹为 Y_t 。在解存在且具有相同边缘路径的条件下,

$$\begin{aligned} & \mathbb{E} \|Y_1 - Y_0\|^2 \leq \int_0^1 \mathbb{E} \|\dot{Y}_t\|^2 \, dt \\ &= \int_0^1 \mathbb{E} \|v_t(X_t)\|^2 \, dt \leq \mathbb{E} \|D\|^2. \end{aligned}$$

第一个不等式来自时间积分上的 Cauchy–Schwarz，最后一个来自条件期望的 Jensen 不等式。定义轨迹速度偏离端点平均速度的程度为

$$S(Y) = \int_0^1 \mathbb{E} \left[\left| \dot{Y}_t - (Y_1 - Y_0) \right|^2 \right] dt.$$

利用 $\int_0^1 \dot{Y}_t dt = Y_1 - Y_0$ ，展开得到

$$S(Y) = \int_0^1 \mathbb{E} \left[\left| \dot{Y}_t \right|^2 \right] dt - \mathbb{E} \left[\left| \dot{Y}_t (Y_1 - Y_0) \right|^2 \right] \leq \mathbb{E} \left[\left| \dot{Y}_t \right|^2 \right] - \mathbb{E} \left[\left| Y_1 - Y_0 \right|^2 \right].$$

记第 k 轮端点位移的二阶矩为 $C_k = \mathbb{E} \left[\left| Z_1^{(k)} - Z_0^{(k)} \right|^2 \right]$ ，则 $S(Z^{(k+1)}) \leq C_k - C_{k+1}$ 。对 K 轮求和，

$$\sum_{k=0}^{K-1} S(Z^{(k+1)}) \leq C_0 - C_K \leq C_0, \\ \forall 1 \leq k \leq K, S(Z^{(k)}) \leq \frac{C_0}{K}.$$

因此，在精确回归和精确积分的假设下，至少存在一轮的直线偏离度不超过 C_0/K 。该界不保证偏离度逐轮单调下降；有限网络与数值积分还会引入误差。

5. 自编码器、VAE 与潜空间生成

5.1 为什么不直接在像素空间建模？

一张 $H \times W$ 的 RGB 图像包含 $3HW$ 个标量。像素级生成需要处理大量局部细节，而高层语义往往具有更低维的结构。潜空间方法先用编码器压缩图像，再让生成模型学习潜变量分布。

设空间下采样倍数为 f 、潜变量通道数为 c ，则

$$x \in \mathbb{R}^{H \times W \times 3}, \quad z \in \mathbb{R}^{(H/f) \times (W/f) \times c}.$$

潜变量与原图的标量数之比为 $c/(3f^2)$ 。这里的压缩率不只是空间尺寸变化，还受到通道数影响；而计算量还与模型结构、token 数和通道宽度有关。

5.2 普通自编码器与生成模型的区别

普通自编码器使用编码器 E_ϕ 和解码器 D_ψ ：

$$z = E_\phi(x), \quad \hat{x} = D_\psi(z), \quad \mathcal{L}_{\text{rec}} = \mathbb{E}_x \left[\left| x - D_\psi(E_\phi(x)) \right|^2 \right].$$

重建良好并不意味着从标准高斯随机抽一个 z 就能解码出合理图像，因为这个 z 可能根本不在编码后的数据分布中。

自编码器负责压缩与重建，潜空间生成模型负责拟合编码后的数据分布。

5.3 VAE

VAE 不把编码结果看作单点，而是分布，例如

$$\begin{aligned} q_{\phi}(z|x) &= \mathcal{N}(\mu_{\phi}(x), \sigma_{\phi}(x)^2) \\ p(z) &= \mathcal{N}(0, I). \end{aligned}$$

解码器定义 $p_{\psi}(x|z)$ 。利用第 1 节的 ELBO，最小化负下界得到

$$\mathcal{L}_{\text{VAE}} = -\mathbb{E}_{q_{\phi}(z|x)} \log p_{\psi}(x|z) + D_{\text{KL}}(q_{\phi}(z|x) \parallel p(z)).$$

若 $p_{\psi}(x|z) = \mathcal{N}(D_{\psi}(z), \tau^2 I)$ 且 τ 固定，则负对数似然等于 $\|x - D_{\psi}(z)\|^2 / (2\tau^2)$ 加常数。像素 MSE 因而对应一个具体的观测噪声假设，并非任意重建损失都等价于这个高斯似然。

5.4 对角高斯 KL 的显式推导

对第 j 个潜变量， $q_j = \mathcal{N}(\mu_j, \sigma_j^2)$ ， $p_j = \mathcal{N}(0, 1)$ 。由 KL 散度的定义，

$$D_{\text{KL}}(q_j \parallel p_j) = \mathbb{E}_{q_j} \left[-\log \sigma_j - \frac{(z_j - \mu_j)^2}{2\sigma_j^2} + \frac{z_j^2}{2} \right].$$

利用 $\mathbb{E}(z_j - \mu_j)^2 = \sigma_j^2$ 和 $\mathbb{E} z_j^2 = \mu_j^2 + \sigma_j^2$ ，各维相加即可得到

$$D_{\text{KL}}(q_{\phi}(z|x) \parallel p(z)) = \frac{1}{2} \sum_j \left(\mu_j^2 + \sigma_j^2 - 1 - \log \sigma_j^2 \right).$$

训练中常预测对数方差 $\ell_j = \log \sigma_j^2$ ，此时方差为 e^{ℓ_j} ，标准差为 $e^{\ell_j/2}$ 。

5.5 重参数化技巧

采样写成

$$\epsilon \sim \mathcal{N}(0, I), \quad z = \mu_{\phi}(x) + \sigma_{\phi}(x) \odot \epsilon.$$

$\odot$ 表示逐元素乘法。随机变量 ϵ 的分布不依赖参数, z 则是编码器输出的可微函数, 因此重建损失的梯度可以沿该变换传回编码器。

KL 过强时, 编码器可能忽略输入, 使 $q_{\phi}(z|x)$ 接近先验而丢失信息; 这种风险需要与重建质量一同考虑。调节 KL 系数可以改变两者平衡, 但系数不为 1 的目标一般不再是原始 ELBO 本身。

5.6 为什么像素 MSE 容易产生模糊?

固定潜变量 z , 设解码器输出为 a , 记 $m = \mathbb{E}[x|z]$ 。展开 $x - a = (x - m) + (m - a)$, 并利用 $\mathbb{E}[x - m] = 0$ 消去交叉项, 得到

$$\mathbb{E}[\|x - a\|^2|z] = \mathbb{E}[\|x - \mathbb{E}[x|z]\|^2|z] + \mathbb{E}[\|a - \mathbb{E}[x|z]\|^2|z].$$

所以最优输出是 $a = \mathbb{E}[x|z]$ 。若压缩丢失了细节, 而某个 z 对应多种纹理或边缘位置, 平均这些可能的图像就可能变得模糊。

课件中还讨论了感知损失和对抗损失。感知损失比较特征空间中的差异, 例如

$$\mathcal{L}_{\text{perc}} = \sum_l w_l \|\Phi_l(x) - \Phi_l(\hat{x})\|^2,$$

其中 Φ_l 是特征提取网络的第 l 层; LPIPS 是具有更具体归一化、加权方式的感知度量。对抗损失则利用判别器鼓励解码图像具有逼真的局部统计。

一个常见的组合形式是

$$\mathcal{L}_{\text{AE}} = \lambda_{\text{rec}} \mathcal{L}_{\text{rec}} + \lambda_{\text{perc}} \mathcal{L}_{\text{perc}} + \lambda_{\text{KL}} \mathcal{L}_{\text{KL}} + \lambda_{\text{adv}} \mathcal{L}_{\text{adv}}.$$

各损失项及其权重依具体模型设定。感知与对抗损失可以改善视觉质量, 但不保证新增细节忠实于原图。

5.7 Latent diffusion / latent flow 的两阶段训练

第一阶段训练自编码器, 使潜变量保留足够的可重建信息。第二阶段通常冻结自编码器, 收集图像编码后的潜变量, 并在其上训练生成模型。

以 flow matching 为例, 这一节记真实图像的编码为 z_1 、高斯噪声为 z_0 :

$$z_t = (1 - t)z_0 + tz_1, \quad \mathcal{L}_{\text{latent-FM}} = \mathbb{E}[\|v_{\theta}(z_t, t, c) - (z_1 - z_0)\|^2].$$

c 是可选的文本或类别条件。若使用 VAE, z_1 可以来自编码后验的采样, 也可以按具体实现使用其均值; 缩放、平移和归一化约定必须在训练与推理中保持一致。

生成时先采样 z_0 , 在潜空间解 ODE 得到 $\hat{z}_1$, 再解码 $\hat{x} = D_\psi(\hat{z}_1)$ 。使用 DDPM 时, 则在潜空间学习噪声预测并运行反向去噪链。

VAE 的 KL 正则不保证编码后的数据分布精确等于标准高斯; 潜空间生成器仍需拟合这一分布。



图 3 潜空间生成与解码。生成模型先将噪声变换为数据潜变量, 解码器再将其映射回像素空间。图中解码器参数记作 θ , 本文记作 ψ 。来源: CME 296 Lecture 4, 第 58 页。

6. 条件生成、DiT 与 MM-DiT

DDPM、得分匹配与流匹配规定训练目标和生成动力学; U-Net、DiT 等网络用于表示相应的预测函数。

6.1 文本条件与注意力

文本经分词器和文本编码器转换为向量序列。Transformer 的缩放点积注意力为

$$\text{Attention}(Q, K, V) = \text{softmax}\left(\frac{QK^{\top}}{\sqrt{d_k}}\right)V.$$

Q 用于提出查询, K 用于匹配, V 是被加权汇总的内容。Self-attention 的三者来自同一序列; cross-attention 中, 查询和键值来自不同序列, 例如图像 token 查询文本 token。

缩放因子的推导。 若各 $q_{i,k}$ 相互独立、均值为零且方差为 1, 则 $\mathbb{E}[q_{ik}] = 0$, $\mathbb{E}[q_i^2 k_i^2] = 1$, 因此

$$\text{Var}(q^{\top} k) = \sum_{i=1}^{d_k} \text{Var}(q_{ik}) = d_k.$$

除以 $\sqrt{d_k}$ 可使点积的方差保持在约 1 的尺度, 减轻维度增长造成的 softmax 饱和。这是初始化尺度上的解释, 不要求训练中的特征始终严格独立。

6.2 CLIP 的图文对齐

CLIP 分别编码图像与文本, 再用配对关系训练相似度。以归一化后的图像向量 a_i 、文本向量 b_j 为例, 相似度可写为 $s_{ij} = a_i^{\top} b_j / \tau$, 其中 τ 为温度。

图像到文本方向的对比损失是

$$\mathcal{L}_{\text{L to T}} = -\frac{1}{N} \sum_{i=1}^N \log \frac{\exp(s_{ii})}{\sum_{j=1}^N \exp(s_{ij})}.$$

再与文本到图像方向的损失取平均, 就同时鼓励真实配对接近、批次中的非配对分离。它学习的是跨模态语义对齐, 不等于训练一个可以精确重建像素的图像自编码器。

在生成模型中，全局文本向量适合提供整体语义，token 级文本特征还保留更细粒度的信息；具体选用哪些编码器和哪一层特征，取决于模型设计。

6.3 DiT：将潜变量变成 token

设潜变量为 $h \times w \times c$ ，使用 $p \times p$ 的 patch，且 p 整除 h, w 。每个 patch 展平成 p^2c 维向量，再线性投影到隐藏维度 d ，token 数为

$$N = \frac{h}{p} \frac{w}{p}.$$

例如 $32 \times 32 \times 4$ 的潜变量，使用 2×2 patch，会得到 256 个 token；每个原始 patch 包含 16 个标量，再映射到模型隐藏维度。

之后加入位置信息，通过多个 Transformer block，最后将输出 token 投影回 patch 并 unpatchify，恢复与潜变量对应的空间布局。网络可以预测噪声、速度或其他参数化目标；DiT 本身并不限定只能预测一种量。

6.4 adaLN-Zero：时间与条件如何进入每一层？

adaLN-Zero 通过缩放、平移和门控，将条件注入残差块。时间嵌入与类别等条件组成向量 c_t ，经 MLP 产生两组参数 $(\gamma_1, \beta_1, \alpha_1)$ 和 $(\gamma_2, \beta_2, \alpha_2)$ 。

 DiT 的 adaLN-Zero 模块：条件向量生成缩放、平移与门控参数，分别调制注意力和前馈残差分支

图 4 adaLN-Zero 的条件注入。每个 DiT 块包含注意力与前馈网络两条残差分支，各自使用一组缩放、平移和门控参数。来源：CME 296 Lecture 5，第 72 页；课件注明改编自 Peebles 与 Xie 的 DiT 工作。

对输入 token h ，一个典型 block 可写为

$$\begin{aligned} \tilde{h}_1 &= (1 + \gamma_1) \odot \text{LN}(h) + \beta_1, \\ h' &= h + \alpha_1 \odot \text{MSA}(\tilde{h}_1), \\ \tilde{h}_2 &= (1 + \gamma_2) \odot \text{LN}(h') + \beta_2, \\ h_{\text{out}} &= h' + \alpha_2 \odot \text{MLP}(\tilde{h}_2). \end{aligned}$$

MSA 是多头自注意力。 γ 控制缩放， β 控制平移， α 控制残差支路注入强度；这些参数通常沿 token 维广播，而非每个 token 独立生成。

“Zero”的关键是通过零初始化等设计，使残差门在初始化时为零，从而让 block 起始状态接近恒等映射。写成 $1+\gamma$ 时，零调制对应不改变缩放。不同资料也会直接用 γ 表示整体缩放，此时应注意符号约定。

6.5 MM-DiT 的多模态联合注意力

一个全局条件向量可能不足以描述复杂的文字—图像关系。MM-DiT 在模态专属的处理分支基础上，通过联合注意力让图像和文本 token 交换信息。

 MM-DiT 总体架构及单个模块：文本与图像分别投影，在联合注意力中交换信息，再进入各自的残差分支

图 5 MM-DiT 总体架构（左）与单个模块（右）。来源：Esser 等，[Scaling Rectified Flow Transformers for High-Resolution Image Synthesis](#), 2024, 图 2。点击图片可查看原尺寸。

图中，池化文本特征与时间嵌入用于生成调制参数，文本序列特征则作为 token 参与联合注意力；含噪潜变量经分块和线性投影形成图像 token。注意：原图用 $\odot$ 表示拼接、用 $*$ 表示逐元素乘法，与本文公式中 $\odot$ 的约定不同。

设图像和文本分别得到 (Q_I, K_I, V_I) 与 (Q_T, K_T, V_T) ，一种核心操作是沿序列维拼接：

$$\begin{aligned} Q &= \text{concat}(Q_I, Q_T), \quad K = \text{concat}(K_I, K_T), \quad V = \text{concat}(V_I, V_T). \end{aligned}$$

然后在合并序列上计算 attention，并将输出拆回对应模态，继续经过各自的处理层。这样，图像 token 可以关注文本 token，文本 token 也可以利用图像上下文。

联合注意力不同于单向交叉注意力：后者使用图像查询与文本键值，前者允许两种模态在共同的注意力计算中双向交互。

6.6 旋转位置编码 RoPE

位置编码使注意力能够区分 token 的顺序或空间位置。RoPE 对 query 和 key 的二维通道对施加旋转。单个二维平面的旋转矩阵记为

$$R(\theta) = \begin{pmatrix} \cos \theta & -\sin \theta \\ \sin \theta & \cos \theta \end{pmatrix}.$$

位置 m, n 的变换分别为 $q'_m = R(m\omega)q_m$ 、 $k'_n = R(n\omega)k_n$ ，于是

$$(q'_m)^\top k'_n = q_m^\top R((n-m)\omega)k_n.$$

这个等式来自 $R(a)^\top R(b) = R(b-a)$ ，表明点积中的位置作用可以由相对位移 $n-m$ 表达。完整 RoPE 在多个通道对上使用不同频率；二维图像还需要把行、列坐标纳入设计，具体分配方式并非只有一种。

6.7 Classifier guidance 与 classifier-free guidance

由贝叶斯公式，条件得分满足

\$\$

$$\nabla_x \log p_t(x|c) = \nabla_x \log p_t(x) + \nabla_x \log p_t(c|x).$$

\$\$

因此 classifier guidance 可以利用一个在噪声图像上训练的分类器，提供额外的条件梯度。但这需要另一个模型，并且它必须适应相应噪声水平。

Classifier-free guidance (CFG) 通过训练时随机丢弃条件，让同一个生成网络同时学习条件预测与无条件预测。采用下面的强度约定：

\$\$

$$s_{\mathrm{guided}} = s_{\mathrm{uncond}} + w(s_{\mathrm{cond}} - s_{\mathrm{uncond}}).$$

\$\$

$w=0$ 为无条件预测， $w=1$ 为普通条件预测， $w>1$ 为强化引导。另一些资料写成 $(1+w)s_{\mathrm{cond}} - ws_{\mathrm{uncond}}$ ，对应的数值约定不同，不能直接比较超参数。

当条件得分与无条件得分均精确时，

\$\$

$$s_{\mathrm{guided}} = \nabla_x \log [p_t(x)^{1-w} p_t(x|c)^w].$$

\$\$

该等式描述固定时刻的密度重加权，不保证最终采样分布也具有相同形式，因为重加权后的各时刻密度未必满足原有动力学。

噪声预测与速度预测也常使用同类线性组合，但得分函数的概率解释不能直接推广到任意速度场。过强引导可能降低多样性或引入失真。