

目录

1. 概率基础与变分推断
2. DDPM
3. Score matching、SDE 与概率流 ODE
4. Flow matching 与 rectified flow
5. 自编码器、VAE 与潜空间生成
6. 条件生成、DiT 与 MM-DiT

Before Reading:

全文中，随机向量均用小写字母表示， I 为单位矩阵， $\mathcal{N}(\mu, \Sigma)$ 为高斯分布。 $\mathbb{E}$ 表示期望， ∇_x 表示对 x 求梯度。

DDPM 与正向 SDE： x_0 是数据，时间增大意味着加噪；生成时从大时间向小时间走。

Flow matching： x_0 是噪声， x_1 是数据；生成时从 $t=0$ 积分到 $t=1$ 。

1. 概率基础与变分推断

1.1 联合分布、条件分布与边缘分布

概率的乘法公式为

$$p(x, z) = p(x \mid z) p(z) = p(z \mid x) p(x).$$

其中 $p(x, z)$ 描述两个变量同时取值的规律， $p(x \mid z)$ 描述固定 z 后 x 的分布。对不关心的变量积分，就得到边缘分布：

$$p(x) = \int p(x, z) \mathrm{d}z.$$

将乘法公式重复展开，可以得到链式分解：

$$p(x_0, \dots, x_T) = p(x_0) \prod_{t=1}^T p(x_t \mid x_0, \dots, x_{t-1}).$$

若过程满足马尔可夫性，即下一步只依赖当前状态，则条件可以简化成 $p(x_t \mid x_{t-1})$ 。DDPM 的正向加噪过程正是这样构造的。

1.2 各向同性高斯与重参数化

对 $x \in \mathbb{R}^d$ ，各向同性高斯的密度为

$$p(x) = \frac{1}{(2\pi\sigma^2)^{d/2}} \exp\left(-\frac{\|x - \mu\|^2}{2\sigma^2}\right).$$

\$\$

各向同性表示协方差为 $\sigma^2 I$ ：不同坐标不相关，且每个方向的方差相同。采样可以写成

\$\$

$\epsilon \sim \mathcal{N}(0, I), \text{qqquad } x = \mu + \sigma \epsilon.$

\$\$

这样把随机性集中到 ϵ ，把分布参数放进一个确定性变换。这种写法既方便推导扩散过程，也使 VAE 可以通过采样节点反向传播。

1.3 KL 散度与 ELBO

设 z 是潜变量，模型的联合分布为 $p_{\theta}(x, z) = p_{\theta}(x | z)p(z)$ 。我们希望最大化 $\log p_{\theta}(x)$ ，但对 z 的积分往往难以直接计算。

引入近似后验 $q_{\phi}(z | x)$ ，在相应密度和积分存在、支持集兼容的条件下，有

\$\$

$\log p_{\theta}(x) = \log \mathbb{E}_{q_{\phi}(z | x)} \left[\frac{p_{\theta}(x, z)}{q_{\phi}(z | x)} \right].$

\$\$

由于 $\log$ 是凹函数，Jensen 不等式给出

\$\$

$\log p_{\theta}(x) \geq \mathbb{E}_{q_{\phi}(z | x)} \left[\log p_{\theta}(x, z) - \log q_{\phi}(z | x) \right] = \mathcal{L}_{\text{ELBO}}.$

\$\$

ELBO 是 evidence lower bound，即对数边缘似然的下界。展开联合分布后，得到更直观的形式：

\$\$

$\mathcal{L}_{\text{ELBO}} = \mathbb{E}_{q_{\phi}(z | x)} [\log p_{\theta}(x | z)] - D_{\text{KL}}(q_{\phi}(z | x) \| p_{\theta}(z)).$

\$\$

第一项要求潜变量能够重建观测，第二项约束编码分布不要任意偏离先验。

由 Bayes 公式 $p_{\theta}(x, z) = p_{\theta}(z | x)p_{\theta}(x)$ ，直接整理可得

\$\$

$\log p_{\theta}(x) - \mathcal{L}_{\text{ELBO}} = D_{\text{KL}}(q_{\phi}(z | x) \| p_{\theta}(z | x)) \geq 0.$

\$\$

因此，下界的松紧由近似后验与真实后验的差距决定；二者几乎处处相等时取等号。DDPM 和 VAE 都可以放进这个变分推断框架，只是它们对潜变量的选择不同。

2. DDPM

2.1 正向加噪

设 $x_0 \sim p(\text{data})$, $0 < \beta_t < 1$, 并记

$$\alpha_t = 1 - \beta_t, \quad \bar{\alpha}_t = \prod_{s=1}^t \alpha_s, \quad \bar{\alpha}_0 = 1.$$

正向转移定义为

$$q(x_t \mid x_{t-1}) = \mathcal{N}(\sqrt{\alpha_t} x_{t-1}, \beta_t).$$

等价地, $x_t = \sqrt{\alpha_t} x_{t-1} + \sqrt{\beta_t} \epsilon_t$, 其中各步的 ϵ_t 独立且服从标准高斯。

递推展开后, 数据项的系数为 $\sqrt{\bar{\alpha}_t}$, 其余项是独立高斯的线性组合, 仍为高斯。若累计噪声方差为 v_t , 则

$$v_t = \alpha_t v_{t-1} + \beta_t = \alpha_t (1 - \bar{\alpha}_{t-1}) + 1 - \alpha_t = 1 - \bar{\alpha}_t.$$

所以

$$q(x_t \mid x_0) = \mathcal{N}(\sqrt{\bar{\alpha}_t} x_0, (1 - \bar{\alpha}_t)I),$$

$$x_t = \sqrt{\bar{\alpha}_t} x_0 + \sqrt{1 - \bar{\alpha}_t} \epsilon, \quad \epsilon \sim \mathcal{N}(0, I).$$

这意味着训练时只需随机抽一个 t , 就能构造相应噪声水平的样本, 不必真的运行前 t 步。若 $\bar{\alpha}_T$ 足够接近零, 终点分布近似标准高斯; 有限步下通常只是近似, 而非严格相等。

2.2 反向去噪

生成模型从 $p(x_T) = \mathcal{N}(0, I)$ 出发, 学习

$$p_{\theta}(x_{0:T}) = p(x_T) \prod_{t=1}^T p_{\theta}(x_{t-1} \mid x_t).$$

真实反向分布 $q(x_{t-1} \mid x_t)$ 一般难以直接求出, 但训练时知道干净样本 x_0 , 因此可以使用解析可得的 $q(x_{t-1} \mid x_t, x_0)$ 。

对 $t \geq 2$, Bayes 公式给出

$$q(x_{t-1} \mid x_t, x_0) \propto q(x_t \mid x_{t-1}) q(x_{t-1} \mid x_0).$$

令 $y = x_{t-1}$ ，忽略与 y 无关的常数，其对数为

$$-\frac{\|x_t - \sqrt{\alpha_t} y\|^2}{2\beta_t} - \frac{\|y - \sqrt{\bar{\alpha}_{t-1}} x_0\|^2}{2(1 - \bar{\alpha}_{t-1})}.$$

二次项的精度和一次项的系数分别为

$$\tilde{\beta}_t^{-1} = \frac{\alpha_t}{\beta_t} + \frac{1}{1 - \bar{\alpha}_{t-1}},$$

$$\tilde{\beta}_t^{-1} \tilde{\mu}_t = \frac{\sqrt{\alpha_t}}{\beta_t} x_t + \frac{\sqrt{\bar{\alpha}_{t-1}}}{1 - \bar{\alpha}_{t-1}} x_0.$$

于是

$$\tilde{\beta}_t = \frac{1 - \bar{\alpha}_{t-1}}{\frac{\alpha_t}{\beta_t} + 1} \beta_t,$$

$$\tilde{\mu}_t = \frac{\sqrt{\bar{\alpha}_{t-1}} \beta_t}{1 - \bar{\alpha}_{t-1}} x_0 + \frac{\sqrt{\alpha_t} (1 - \bar{\alpha}_{t-1})}{1 - \bar{\alpha}_{t-1}} x_t.$$

把 $x_0 = (x_t - \sqrt{1 - \bar{\alpha}_t} \epsilon) / \sqrt{\bar{\alpha}_t}$ 代入，又得到

$$\tilde{\mu}_t = \frac{1}{\sqrt{\alpha_t}} \left(x_t - \frac{\beta_t}{\sqrt{1 - \bar{\alpha}_t}} \epsilon \right).$$

这就是学习预测噪声能够确定去噪均值的原因。

2.3 从 ELBO 到噪声预测损失

把整条轨迹 $x_{1:T}$ 当作潜变量。负 ELBO 可以整理为

$$\mathcal{J}_{\mathrm{VLB}} = \mathbb{E}_q[-\log p(L_T + \sum_{t=2}^T L_{t-1} + L_0)],$$

其中三类项分别是

$$L_T = D_{\mathrm{KL}}(q(x_T \mid x_0) \parallel p(x_T)),$$

\$\$

$$L_{t-1} = D_{\{\mathrm{KL}\}} \left(q(x_{t-1} \mid x_t, x_0), \mathrm{p}_{\{\theta\}}(x_{t-1} \mid x_t) \right),$$

\$\$

\$\$

$$L_0 = -\log p_{\{\theta\}}(x_0 \mid x_1).$$

\$\$

这个分解可由条件链式分解 $q(x_{1:T} \mid x_0) = q(x_T \mid x_0) \prod_{t=2}^T q(x_{t-1} \mid x_t, x_0)$ 代入 ELBO 得到。 L_T 匹配终点先验, L_{t-1} 学习反向转移, L_0 是最后一步的数据重建项。

设模型方差固定为 σ_t^2 , 并用网络 $\epsilon_{\{\theta\}}(x_t, t)$ 替代后验均值公式中的噪声。高斯 KL 中依赖均值的部分为

\$\$

$$L_{t-1} = \frac{\beta_t^2}{2\sigma_t^2 \alpha_t (1 - \bar{\alpha}_t)} \left\| \epsilon_{\{\theta\}}(x_t, t) \right\|^2 + C_t.$$

\$\$

这里 C_t 与均值网络参数无关, 但这个表述依赖于“方差固定”的假设。如果方差也要学习, 不能直接丢弃所有方差项。

实际常用的简化目标去掉了上述时间权重:

\$\$

$$\mathcal{L}_{\{\mathrm{simple}\}} = \mathbb{E}_{t, x_0, \epsilon} \left[\left\| \epsilon_{\{\theta\}}(\sqrt{\bar{\alpha}_t} x_0 + \sqrt{1 - \bar{\alpha}_t} \epsilon, t) \right\|^2 \right].$$

\$\$

因此, 简化噪声 MSE 与原始负 ELBO 不是完全相同的目标, 它们对不同噪声水平赋予了不同权重。

2.4 训练与采样

训练时抽取数据、时间和噪声, 直接构造 x_t , 再做一次噪声预测回归。虽然单个 x_t 不能唯一确定当初加入的噪声, 但平方损失的最优解是条件均值 $\mathbb{E}[\epsilon \mid x_t, t]$ 。

采样时从 $x_T \sim \mathcal{N}(0, I)$ 开始, 按 $t = T, \dots, 1$ 更新:

\$\$

$$x_{t-1} = \frac{1}{\sqrt{\alpha_t}} \left(x_t - \frac{\beta_t}{\sqrt{1 - \bar{\alpha}_t}} \epsilon_{\{\theta\}}(x_t, t) \right) + \sigma_t \xi.$$

\$\$

其中 $\xi \sim \mathcal{N}(0, I)$, 常见实现最后一步不再额外加噪。 σ_t 的选择应与模型、训练和采样器的设定一致。

2.5 DDIM

DDIM 不要求采样时严格遵循原来的马尔可夫反向链。先估计干净样本:

\$\$

$$\hat{x}_0 = \frac{x_t - \sqrt{1 - \bar{\alpha}_t} \epsilon_{\theta}(x_t, t)}{\sqrt{\bar{\alpha}_t}}.$$

\$\$

对于较早时刻 $s < t$ ，确定性的 DDIM 更新写为

\$\$

$$x_s = \sqrt{\bar{\alpha}_s} \hat{x}_0 + \sqrt{1 - \bar{\alpha}_s} \epsilon_{\theta}(x_t, t).$$

\$\$

它利用同一去噪预测构造下一状态，可以选取较稀疏的时间网格。但网络误差和离散化误差仍会影响质量。所谓确定性，也是指给定初始噪声后轨迹确定，而非所有初始噪声产生同一张图。

3. Score matching、SDE 与概率流 ODE

3.1 Score 是什么？

概率密度 $p_t(x)$ 的 score 定义为

\$\$

$$s_t(x) = -\nabla_x \log p_t(x).$$

\$\$

它是一个与 x 同维的向量，指向局部对数密度上升最快的方向。若密度只差一个与 x 无关的归一化常数，取梯度后该常数消失。

但如果只沿 score 做梯度上升会寻找高密度区域，无法自动得到分布采样。Langevin 动力学还需要噪声：

\$\$

$$x_{k+1} = x_k + \eta s(x_k) + \sqrt{2\eta} \xi_k.$$

\$\$

在合适的正则性与遍历条件下，对应的连续过程以 p 为平稳分布；有限步长的离散算法通常仍有偏差。

3.2 去噪得分匹配

设扰动核为

\$\$

$$q_t(x_t | x_0) = \mathcal{N}(m_{t,x_0}, \nu_t^2).$$

\$\$

它的条件 score 可以直接计算：

\$\$

$$\nabla_{x_t} \log q_t(x_t | x_0) = -\frac{x_t - m_{t,x_0}}{\nu_t^2} = -\frac{\epsilon_{\theta}(x_t, t)}{\nu_t}.$$

\$\$

然而采样需要的是边缘分布 $p_t(x_t) = \int q_t(x_t | x_0) p_{\text{data}}(x_0) dx_0$ 的 score。

在可以交换微分与积分的条件下,

$$\nabla_x \log p_t(x) = \frac{\int \nabla_x q_t(x \mid x_0) p_{\{\mathrm{data}\}}(x_0) \mathrm{d}x_0}{p_t(x)}.$$

利用 $\nabla q = q \nabla \log q$ 和 Bayes 公式, 得到

$$\nabla_x \log p_t(x) = \mathbb{E}[\nabla_x \log q_t(x \mid x_0) \mid x_t = x].$$

记条件 score 为随机向量 Y , 其条件均值为 $\bar{Y} = \mathbb{E}[Y \mid x_t, t]$. 平方误差分解为

$$\mathbb{E}[\|s_{\theta} - Y\|^2] = \mathbb{E}[\|s_{\theta} - \bar{Y}\|^2] + \mathbb{E}[\|Y - \bar{Y}\|^2].$$

交叉项为零, 因为 $\mathbb{E}[Y - \bar{Y} \mid x_t, t] = 0$. 第二项与网络参数无关, 所以回归可计算的条件 score, 就等价于学习不可直接计算的边缘 score. 这是 denoising score matching 的关键.

对于 DDPM, 有 $m_t = \sqrt{\bar{\alpha}_t}$ 、 $\nu_t = \sqrt{1 - \bar{\alpha}_t}$, 于是噪声预测与 score 预测的关系为

$$s_{\theta}(x_t, t) = -\frac{\epsilon_{\theta}(x_t, t)}{\sqrt{1 - \bar{\alpha}_t}}.$$

3.3 从 DDPM 到连续时间 SDE

一般正向随机微分方程写作

$$\mathrm{d}x = f(x, t) \mathrm{d}t + g(t) \mathrm{d}W_t.$$

f 是漂移项, 描述确定性变化; W_t 是标准 Wiener 过程, 其增量协方差为 $\mathrm{d}t \mathbf{I}$; g 控制随机扰动强度. 这里假设扩散系数只依赖时间, 若依赖空间, 后面的公式需要相应修正.

将 DDPM 一步的噪声方差设为 $\beta(t) \Delta t$. 用 $\sqrt{1-a} = 1 - a/2 + O(a^2)$ 展开, 有

$$x_{t+\Delta t} - x_t \approx -\frac{1}{2} \beta(t) x_t \Delta t + \sqrt{\beta(t)} \sqrt{\Delta t} \epsilon.$$

连续极限即 variance-preserving SDE:

$$\mathrm{d}x = -\frac{1}{2} \beta(t) x \mathrm{d}t + \sqrt{\beta(t)} \mathrm{d}W_t.$$

“方差保持”并不要求每个给定数据点的条件方差恒定；它指在输入具有单位协方差的条件下，该过程保持单位协方差。另一个常见选择是 VE-SDE，通过不断增大的噪声方差扩散数据。

3.4 反向 SDE

在相应光滑性和时间反演条件下，反向过程为

$$\mathrm{d}x = \left[f(x, t) - g(t)^2 \nabla_x \log p_t(x) \right] \mathrm{d}t + g(t) \mathrm{d}\bar{W}_t.$$

此式按 $t=T$ 到 0 使用， $\mathrm{d}t$ 是负的时间增量， $\bar{W}_t$ 是反向时间中的 Wiener 过程。若使用正步长 $h>0$ 向前编写“反向采样”代码，则 Euler 更新是

$$x_{t-h} \approx x_t - \left[f(x_t, t) - g(t)^2 \nabla_x \log p_t(x_t) \right] h + g(t) \sqrt{h} \xi.$$

3.5 概率流 ODE

与上述 SDE 对应的 probability flow ODE 为

$$\frac{\mathrm{d}x}{\mathrm{d}t} = f(x, t) - \frac{1}{2} g(t)^2 \nabla_x \log p_t(x).$$

推导补充：系数为什么是二分之一？ SDE 的密度满足 Fokker–Planck 方程：

$$\partial_t p_t = -\nabla \cdot (f p_t) + \frac{1}{2} g(t)^2 \Delta p_t.$$

由 $\nabla p_t = p_t \nabla \log p_t$ ，可以改写为

$$\partial_t p_t = -\nabla \cdot \left[p_t \left(f - \frac{1}{2} g(t)^2 \nabla \log p_t \right) \right].$$

这恰好是速度场 $f - \frac{1}{2} g^2 \nabla \log p_t$ 的连续性方程。因此，在使用精确 score、相同初始密度并满足解的条件时，ODE 与 SDE 具有相同的单时刻边缘分布。

相同边缘分布不等于相同轨迹或相同联合路径分布。 ODE 给定起点后是确定性轨迹，SDE 则沿途持续注入随机性；网络近似和数值积分还会引入额外误差。

4. Flow matching 与 rectified flow

x_0 为简单先验噪声， x_1 为数据。

4.1 轨迹、速度场与概率路径

三种对象需要区分：

轨迹 $x_t = \psi_t(x_0)$ ：一个粒子随时间如何运动。

速度场 $u_t(x)$ ：时间 t 、位置 x 处应当具有的速度。

概率路径 p_t ：所有粒子共同形成的分布如何变化。

它们通过 ODE 连接：

\$\$

$$\frac{d}{dt}\psi_t(x_0) = u_t(\psi_t(x_0)), \quad \psi_0(x_0) = x_0.$$

\$\$

给定初始分布 p_0 ，流映射将其推到 $p_t = (\psi_t)_\# p_0$ 。“推送分布”表示先采样 x_0 ，再做确定性变换 ψ_t 。

4.2 为什么强调 Lipschitz 条件？

若速度场对时间连续、对空间局部 Lipschitz，通常可保证 ODE 初值问题局部存在且唯一。

例如 $\dot{x} = \sqrt{x}$ 、 $x(0) = 0$ 在非负半轴上不满足原点附近的 Lipschitz 条件。除了恒等于零的解，对于任意 $c \geq 0$ ，还有

\$\$

$$x(t) = \begin{cases} 0, & 0 \leq t \leq c, \\ (t-c)^2/4, & t > c. \end{cases}$$

\$\$

同一个初值可以“等一会儿再出发”，因此解不唯一。这个例子说明规则性假设有实际作用；并不是所有不满足 Lipschitz 的 ODE 都必然不唯一。

4.3 连续性方程的推导

粒子流既不创造也不消灭概率质量，所以密度满足

\$\$

$$\partial_t p_t(x) + \nabla \cdot (p_t(x) u_t(x)) = 0.$$

\$\$

证明：取光滑且紧支撑的函数 φ 。由链式法则，

\$\$

$$\frac{d}{dt} \int \varphi(x) p_t(x) dx = \int \nabla \varphi(x) \cdot u_t(x) p_t(x) dx.$$

\$\$

分部积分后右侧等于 $-\int \varphi(x) \nabla \cdot (p_t u_t) dx$ ；左侧等于 $\int \varphi(x) \partial_t p_t(x) dx$ 。因为对所有这样的 φ 都成立，就得到连续性方程的弱形式。

4.4 从条件路径构造可训练的速度

最简单的插值为

\$\$

$$x_t = (1-t)x_0 + tx_1, \text{quad} \dot{x}_t = x_1 - x_0.$$

\$\$

固定一个数据点 x_1 , 若 $x_0 \sim \mathcal{N}(0, I)$ 且与它独立, 则

\$\$

$$p_t(x \mid x_1) = \mathcal{N}(tx_1, (1-t)^2 I), \text{quad} 0 \leq t < 1.$$

\$\$

由 $x_0 = (x - tx_1)/(1-t)$ 得到条件速度场

\$\$

$$u_t(x \mid x_1) = \frac{x_1 - x}{1-t}.$$

\$\$

沿采样得到的插值点代入, 这个表达式就等于 $x_1 - x_0$ 。后者是训练时更直接、也无需除以 $1-t$ 的目标。

当 $t \rightarrow 1$ 时, 上述条件高斯收缩成点质量, 因此带分母的公式不能直接在 $t=1$ 代入。训练通常从连续区间采样时间, 实际求解也需要妥善处理端点。

4.5 边缘速度为什么是条件速度的后验平均?

边缘概率路径为

\$\$

$$p_t(x) = \int p_t(x \mid x_1) p_{\{\mathrm{data}\}}(x_1) \mathrm{d}x_1.$$

\$\$

每个条件路径都满足连续性方程。将这些方程对 x_1 积分, 就有

\$\$

$$\partial_t p_t(x) = -\nabla \cdot \int p_t(x \mid x_1) u_t(x \mid x_1) p_{\{\mathrm{data}\}}(x_1) \mathrm{d}x_1.$$

\$\$

因此一个能够生成该边缘路径的速度场是

\$\$

$$u_t(x) = \frac{\int p_t(x \mid x_1) u_t(x \mid x_1) p_{\{\mathrm{data}\}}(x_1) \mathrm{d}x_1}{p_t(x)} = \mathbb{E}[u_t(x \mid x_1) \mid x_t = x].$$

\$\$

注意平均的权重是后验 $p(x_1 \mid x_t = x)$, 不是对所有数据点做等权平均。给定一条密度路径, 能够实现它的速度场也不必唯一; 这里构造的是其中一个。

4.6 FM 与 CFM 的等价性

理想的 flow matching 目标是

\$\$

$$\mathcal{L}_{\{\mathrm{FM}\}} = \mathbb{E}_{t,x_t} \|\mathbf{v}_t \theta(x_t, t) - \mathbf{u}_t(x_t)\|^2,$$

\$\$

但边缘速度难以计算。实际训练采用 conditional flow matching :

\$\$

$$\mathcal{L}_{\{\mathrm{CFM}\}} = \mathbb{E}_{t,x_0,x_1} \|\mathbf{v}_t \theta((1-t)x_0 + tx_1, t) - (x_1 - x_0)\|^2.$$

\$\$

证明：为什么目标可以替换？

令 $U = x_1 - x_0$, $\bar{U} = \mathbb{E}[U \mid x_t, t] = \mathbf{u}_t(x_t)$ 。展开平方误差并使用条件期望，得到

\$\$

$$\mathcal{L}_{\{\mathrm{CFM}\}} = \mathcal{L}_{\{\mathrm{FM}\}} + \mathbb{E} \|\mathbf{U} - \bar{\mathbf{U}}\|^2.$$

\$\$

第二项不依赖 θ ，所以两个目标具有相同的参数梯度和最优解。这与去噪得分匹配背后的原理相同：使用容易采样的条件监督，学习边缘场。

训练时不必求解 ODE；只需采样 (x_0, x_1, t) 并做速度回归。采样时才从 $x_0 \sim p_0$ 出发，解 $\dot{x}_t = \mathbf{v}_t \theta(x_t, t)$ 。

4.7 rectified flow 与 reflow

在这里讨论的线性插值、速度回归设定下，rectified flow 与前面的训练形式一致。Reflow 则使用已学到的 ODE 建立新的端点对：采样 Z_0 ，积分得到 Z_1 ，再基于这对端点的直线插值重新训练。

直观上，新的配对已经包含旧模型学到的传输关系，不再是任意独立配对。下面的推导说明为什么这种操作有利于减少无效弯曲，但结论需要理想化假设。

推导补充：一个能量不等式。

对旧端点对 (Z_0, Z_1) ，记 $D = Z_1 - Z_0$ 、 $X_t = (1-t)Z_0 + tZ_1$ 。设新的精确回归场为 $\mathbf{v}_t(x) = \mathbb{E}[D \mid X_t = x]$ ，由该场产生的新轨迹为 Y_t 。在解存在且具有相同边缘路径的条件下，

\$\$

$$\mathbb{E} \|\mathbf{Y}_1 - \mathbf{Y}_0\|^2 \leq \int_0^1 \mathbb{E} \|\dot{\mathbf{Y}}_t\|^2 dt, \quad \mathbb{E} \|\mathbf{Y}_1 - \mathbf{Y}_0\|^2 \leq \int_0^1 \mathbb{E} \|\mathbf{v}_t(X_t)\|^2 dt \leq \mathbb{E} \|D\|^2.$$

\$\$

第一个不等式来自时间积分上的 Cauchy–Schwarz，最后一个来自条件期望的 Jensen 不等式。定义轨迹速度偏离端点平均速度的程度为

\$\$

$$S(Y) = \int_0^1 \mathbb{E} \|\dot{\mathbf{Y}}_t - (\mathbf{Y}_1 - \mathbf{Y}_0)\|^2 dt.$$

\$\$

利用 $\int_0^1 \dot{\mathbf{Y}}_t dt = \mathbf{Y}_1 - \mathbf{Y}_0$ ，展开得到

\$\$

$$S(Y) = \int_0^1 \|\mathbb{E}[\dot{Y}_t]\|^2 dt - \|\mathbb{E}[Y_1 - Y_0]\|^2 \leq \mathbb{E}[\|D\|^2 - \mathbb{E}[Y_1 - Y_0]^2].$$

\$\$

多轮相加可得到望远镜式能量界，支持“反复 reflow 能找到更直的流”的结论。但这并不直接证明每一轮的 \$\$ 都严格小于上一轮，更不能保证有限网络和有限训练下必然单调改善。少步生成仍需检验实际积分误差与样本质量。

5. 自编码器、VAE 与潜空间生成

5.1 为什么不直接在像素空间建模？

一张 $H \times W$ 的 RGB 图像包含 $3HW$ 个标量。像素级生成需要处理大量局部细节，而高层语义往往具有更低维的结构。潜空间方法先用编码器压缩图像，再让生成模型学习潜变量分布。

设空间下采样倍数为 f 、潜变量通道数为 c ，则

\$\$

$$x \in \mathbb{R}^{H \times W \times 3}, \quad z \in \mathbb{R}^{(H/f) \times (W/f) \times c}.$$

\$\$

潜变量与原图的标量数之比为 $c/(3f^2)$ 。这里的压缩率不只是空间尺寸变化，还受到通道数影响；而计算量还与模型结构、token 数和通道宽度有关。

5.2 普通自编码器与生成模型的区别

普通自编码器使用编码器 E_ϕ 和解码器 D_ψ ：

\$\$

$$z = E_\phi(x), \quad \hat{x} = D_\psi(z), \quad \mathcal{L}_{\text{rec}} = \mathbb{E}_x \|x - D_\psi(E_\phi(x))\|^2.$$

\$\$

重建良好并不意味着从标准高斯随机抽一个 z 就能解码出合理图像，因为这个 z 可能根本不在编码后的数据分布中。

因此需要区分两个任务：自编码器学习“压缩和重建”，潜空间生成模型学习“如何采到像真实编码结果一样的潜变量”。

5.3 VAE

VAE 不把编码结果看作单点，而是分布，例如

\$\$

$$q_\phi(z \mid x) = \mathcal{N}(\mu_\phi(x), \text{diag}(\sigma_\phi(x)^2)), \quad p(z) = \mathcal{N}(0, I).$$

\$\$

解码器定义 $p_\psi(x \mid z)$ 。利用第 1 节的 ELBO，最小化负下界得到

\$\$

$$\mathcal{L}_{\mathrm{VAE}} = -\mathbb{E}_{q_{\phi}(z|x)} \log p_{\psi}(x|z) + D_{\mathrm{KL}}(q_{\phi}(z|x) \parallel p_{\psi}(z)).$$

\$\$

若 $p_{\psi}(x|z) = \mathcal{N}(D_{\psi}(z), \tau^2 I)$ 且 τ 固定，则负对数似然等于 $\|x - D_{\psi}(z)\|^2 / (2\tau^2)$ 加常数。像素 MSE 因而对应一个具体的观测噪声假设，并非任意重建损失都等价于这个高斯似然。

5.4 对角高斯 KL 的显式推导

推导补充。 对第 j 个潜变量， $q_j = \mathcal{N}(\mu_j, \sigma_j^2)$ ，而 $p_j = \mathcal{N}(0, 1)$ 。由定义，

\$\$

$$D_{\mathrm{KL}}(q_j \parallel p_j) = \mathbb{E}_{q_j} \left[-\log \sigma_j - \frac{(z_j - \mu_j)^2}{2\sigma_j^2} + \frac{z_j^2}{2} \right].$$

\$\$

利用 $\mathbb{E}(z_j - \mu_j)^2 = \sigma_j^2$ 和 $\mathbb{E} z_j^2 = \mu_j^2 + \sigma_j^2$ ，各维相加即可得到

\$\$

$$D_{\mathrm{KL}}(q_{\phi}(z|x) \parallel p_{\psi}(z)) = \frac{1}{2} \sum_j \left(\mu_j^2 + \sigma_j^2 - 1 - \log \sigma_j^2 \right).$$

\$\$

训练中常预测 $\ell_j = \log \sigma_j^2$ ，此时方差为 e^{ℓ_j} ，标准差为 $e^{\ell_j/2}$ ，不要把二者混用。

5.5 重参数化技巧

采样写成

\$\$

$$\epsilon \sim \mathcal{N}(0, I), \quad z = \mu_{\phi}(x) + \sigma_{\phi}(x) \odot \epsilon.$$

\$\$

$\odot$ 表示逐元素乘法。固定本次抽取的 ϵ 后， z 是网络输出的可微函数，重建损失的梯度就能传回编码器。蒙特卡洛估计仍具有随机性，但不再需要对一个依赖参数的“抽样操作”直接求普通路径导数。

KL 过强时，编码器可能忽略输入，使 $q_{\phi}(z|x)$ 接近先验而丢失信息；这种风险需要与重建质量一同考虑。调节 KL 系数可以改变两者平衡，但系数不为 1 的目标一般不再是原始 ELBO 本身。

5.6 为什么像素 MSE 容易产生模糊？

推导补充：平方损失偏好条件均值。 固定潜变量 z ，设解码器输出为 a 。有

\$\$

$$\mathbb{E}[\|x - a\|^2 | z] = \mathbb{E}[\|x - \mathbb{E}[x | z]\|^2 | z] + \mathbb{E}[\|a - \mathbb{E}[x | z]\|^2]$$

\$\$

所以最优输出是 $a = \mathbb{E}[x | z]$ 。若压缩丢失了细节，而某个 z 对应多种纹理或边缘位置，平均这些可能的图像就可能变得模糊。

课件中还讨论了感知损失和对抗损失。感知损失比较特征空间中的差异，例如

\$\$

$$\mathcal{L}_{\text{perc}} = \sum_l w_l \|\Phi_l(x) - \Phi_l(\hat{x})\|^2,$$

\$\$

其中 Φ_l 是特征提取网络的第 l 层；LPIPS 是具有更具体归一化、加权方式的感知度量。对抗损失则利用判别器鼓励解码图像具有逼真的局部统计。

一个常见的组合形式是

\$\$

$$\mathcal{L}_{\text{AE}} = \lambda_{\text{rec}} \mathcal{L}_{\text{rec}} + \lambda_{\text{perc}} \mathcal{L}_{\text{perc}} + \lambda_{\text{KL}} \mathcal{L}_{\text{KL}} + \lambda_{\text{adv}} \mathcal{L}_{\text{adv}}.$$

\$\$

这表达的是损失设计框架，不代表所有方法使用同一组项或同样的权重。生成的细节越逼真，也不意味着它们越忠实于原图；对科学图像尤其需要区分“感知质量”和“信息保真”。

5.7 Latent diffusion / latent flow 的两阶段训练

第一阶段训练自编码器，使潜变量保留足够的可重建信息。第二阶段通常冻结自编码器，收集图像编码后的潜变量，并在其上训练生成模型。

以 flow matching 为例，这一节记真实图像的编码为 z_1 、高斯噪声为 z_0 ：

\$\$

$$z_t = (1-t)z_0 + tz_1, \quad \mathcal{L}_{\text{latent FM}} = \mathbb{E}[\|v_{\theta}(z_t, t, c) - (z_1 - z_0)\|^2].$$

\$\$

c 是可选的文本或类别条件。若使用 VAE， z_1 可以来自编码后验的采样，也可以按具体实现使用其均值；缩放、平移和归一化约定必须在训练与推理中保持一致。

生成时先采样 z_0 ，在潜空间解 ODE 得到 $\hat{z}_1$ ，再解码 $\hat{x} = D_{\psi}(\hat{z}_1)$ 。使用 DDPM 时，则在潜空间学习噪声预测并运行反向去噪链。

注意，潜空间生成器学习的是编码数据的实际分布；VAE 的 KL 正则并不保证这个分布已经精确等于标准高斯，否则就不需要再花大力气学习一个潜空间生成器了。

6. 条件生成、DiT 与 MM-DiT

对应课件：Lecture 4 的条件生成，以及 Lecture 5 的模型架构。前面的 DDPM、score matching 和 flow matching 定义训练目标与动力学；U-Net、DiT 等则是用来表示预测函数的网络。目标与架构是不同层次的选择。

6.1 文本条件与注意力

文本通常先经 tokenizer 和文本编码器，变成一串向量。Transformer 的缩放点积注意力为

$$\text{Attention}(Q, K, V) = \text{softmax}\left(\frac{QK^{\top}}{\sqrt{d_k}}\right)V.$$

Q 用于提出查询， K 用于匹配， V 是被加权汇总的内容。Self-attention 的三者来自同一序列；cross-attention 中，查询和键值来自不同序列，例如图像 token 查询文本 token。

推导补充：为什么除以 $\sqrt{d_k}$ ？ 若 q_{i,k_i} 近似独立、均值为零、方差为 1，则

$$\text{Var}(q^{\top}k) = \sum_{i=1}^{d_k} \text{Var}(q_{ik_i}) = d_k.$$

除以 $\sqrt{d_k}$ 可使点积的方差保持在约 1 的尺度，减轻维度增长造成的 softmax 饱和。这是初始化尺度上的解释，不要求训练中的特征始终严格独立。

6.2 课件补充：CLIP 为什么能连接文字与图像？

CLIP 分别编码图像与文本，再用配对关系训练相似度。以归一化后的图像向量 a_i 、文本向量 b_j 为例，相似度可写为 $s_{ij} = a_i^{\top} b_j / \tau$ ，其中 τ 为温度。

图像到文本方向的对比损失是

$$\mathcal{L}_{\text{I to T}} = -\frac{1}{N} \sum_{i=1}^N \log \frac{\exp(s_{ii})}{\sum_{j=1}^N \exp(s_{ij})}.$$

再与文本到图像方向的损失取平均，就同时鼓励真实配对接近、批次中的非配对分离。它学习的是跨模态语义对齐，不等于训练一个可以精确重建像素的图像自编码器。

在生成模型中，全局文本向量适合提供整体语义，token 级文本特征还保留更细粒度的信息；具体选用哪些编码器和哪一层特征，取决于模型设计。

6.3 DiT：将潜变量变成 token

设潜变量为 $h \times w \times c$ ，使用 $p \times p$ 的 patch，且 p 整除 h, w 。每个 patch 展平成 $p^2 c$ 维向量，再线性投影到隐藏维度 d ，token 数为

$$N = \frac{h}{p} \frac{w}{p}.$$

例如 $32 \times 32 \times 4$ 的潜变量，使用 2×2 patch，会得到 256 个 token；每个原始 patch 包含 16 个标量，再映射到模型隐藏维度。

之后加入位置信息，通过多个 Transformer block，最后将输出 token 投影回 patch 并 unpatchify，恢复与潜变量对应的空间布局。网络可以预测噪声、速度或其他参数化目标；DiT 本身并不限定只能预测一种量。

6.4 adaLN-Zero：时间与条件如何进入每一层？

手写笔记中的 scale、shift 和 gate，对应的是自适应归一化与残差门控。将时间嵌入和类别等条件组合为向量 c_t ，经 MLP 产生两组参数 $(\gamma_1, \beta_1, \alpha_1)$ 和 $(\gamma_2, \beta_2, \alpha_2)$ 。

对输入 token h ，一个典型 block 可写为

$$\begin{aligned} \tilde{h}_1 &= (1 + \gamma_1) \odot \text{LN}(h) + \beta_1, \\ h' &= h + \alpha_1 \odot \text{MSA}(\tilde{h}_1), \\ \tilde{h}_2 &= (1 + \gamma_2) \odot \text{LN}(h') + \beta_2, \\ h_{\text{out}} &= h' + \alpha_2 \odot \text{MLP}(\tilde{h}_2). \end{aligned}$$

MSA 是多头自注意力。 γ 控制缩放， β 控制平移， α 控制残差支路注入强度；这些参数通常沿 token 维广播，而非每个 token 独立生成。

“Zero”的关键是通过零初始化等设计，使残差门在初始化时为零，从而让 block 起始状态接近恒等映射。写成 $1 + \gamma$ 时，零调制对应不改变缩放。不同资料也会直接用 γ 表示整体缩放，此时应注意符号约定。

6.5 MM-DiT：不只是把文字变成一个全局向量

一个全局条件向量可能不足以描述复杂的文字—图像关系。MM-DiT 在模态专属的处理分支基础上，通过联合注意力让图像和文本 token 交换信息。

设图像和文本分别得到 (Q_I, K_I, V_I) 与 (Q_T, K_T, V_T) ，一种核心操作是沿序列维拼接：

$$\begin{aligned} Q &= \text{concat}(Q_I, Q_T), \quad K = \text{concat}(K_I, K_T), \quad V = \text{concat}(V_I, V_T). \end{aligned}$$

然后在合并序列上计算 attention，并将输出拆回对应模态，继续经过各自的处理层。这样，图像 token 可以关注文本 token，文本 token 也可以利用图像上下文。

这里需要纠正一个容易混用的术语：**联合注意力不等于单向 cross-attention**。普通图像到文本 cross-attention 使用图像查询和文本键值；联合注意力则把两种模态的 token 放到共同的注意力计算中。各具体架构的末层、调制和参数共享策略还可能不同。

6.6 课件补充：RoPE 如何表达相对位置？

位置编码使注意力能够区分 token 的顺序或空间位置。RoPE 对 query 和 key 的二维通道对施加旋转。单个二维平面的旋转矩阵记为

$$R(\theta) = \begin{pmatrix} \cos \theta & -\sin \theta \\ \sin \theta & \cos \theta \end{pmatrix}.$$

位置 m, n 的变换分别为 $q'_m = R(m\omega)q_m$ 、 $k'_n = R(n\omega)k_n$ ，于是

$$(q'_m)^\top k'_n = q_m^\top R((n-m)\omega)k_n.$$

这个等式来自 $R(a)^\top R(b) = R(b-a)$ ，表明点积中的位置作用可以由相对位移 $n-m$ 表达。完整 RoPE 在多个通道对上使用不同频率；二维图像还需要把行、列坐标纳入设计，具体分配方式并非只有一种。

6.7 Classifier guidance 与 classifier-free guidance

由 Bayes 公式，条件 score 满足

$$\nabla_x \log p_t(x \mid c) = \nabla_x \log p_t(x) + \nabla_x \log p_t(c \mid x).$$

因此 classifier guidance 可以利用一个在噪声图像上训练的分类器，提供额外的条件梯度。但这需要另一个模型，并且它必须适应相应噪声水平。

Classifier-free guidance (CFG) 通过训练时随机丢弃条件，让同一个生成网络同时学习条件预测与无条件预测。采用下面的强度约定：

$$s_{\mathrm{guided}} = s_{\mathrm{uncond}} + w(s_{\mathrm{cond}} - s_{\mathrm{uncond}}).$$

$w=0$ 为无条件预测， $w=1$ 为普通条件预测， $w>1$ 为强化引导。另一些资料写成 $(1+w)s_{\mathrm{cond}} - ws_{\mathrm{uncond}}$ ，对应的数值约定不同，不能直接比较超参数。

推导补充：引导增强了什么？ 当两个 score 都精确时，

$$s_{\mathrm{guided}} = \nabla_x \log \left[p_t(x)^{1-w} p_t(x \mid c)^w \right].$$

这说明在每个固定时刻，引导倾向于放大更符合条件的区域。但不应据此直接断言整条采样过程的最终分布就严格等于对应的幂次重加权分布：不同时间的这些密度未必共同满足原来的动力学。

噪声预测、速度预测中也常采用同样的线性组合。对流匹配速度而言，它可作为常用的引导形式，但不能不加条件地把所有 score 的概率解释原样搬过来。更强引导也并非一定更好，可能牺牲多样性或引入失真。